WORKSHOP: DATA MART TEMÁTICO

INTERNAÇÕES E ÓBITOS

Arthur Almeida de Souza
Guilherme Domiciano Silva
Lucas da Silva Nascimento
Nicole Franca Martins

MODELO DIMENSIONAL

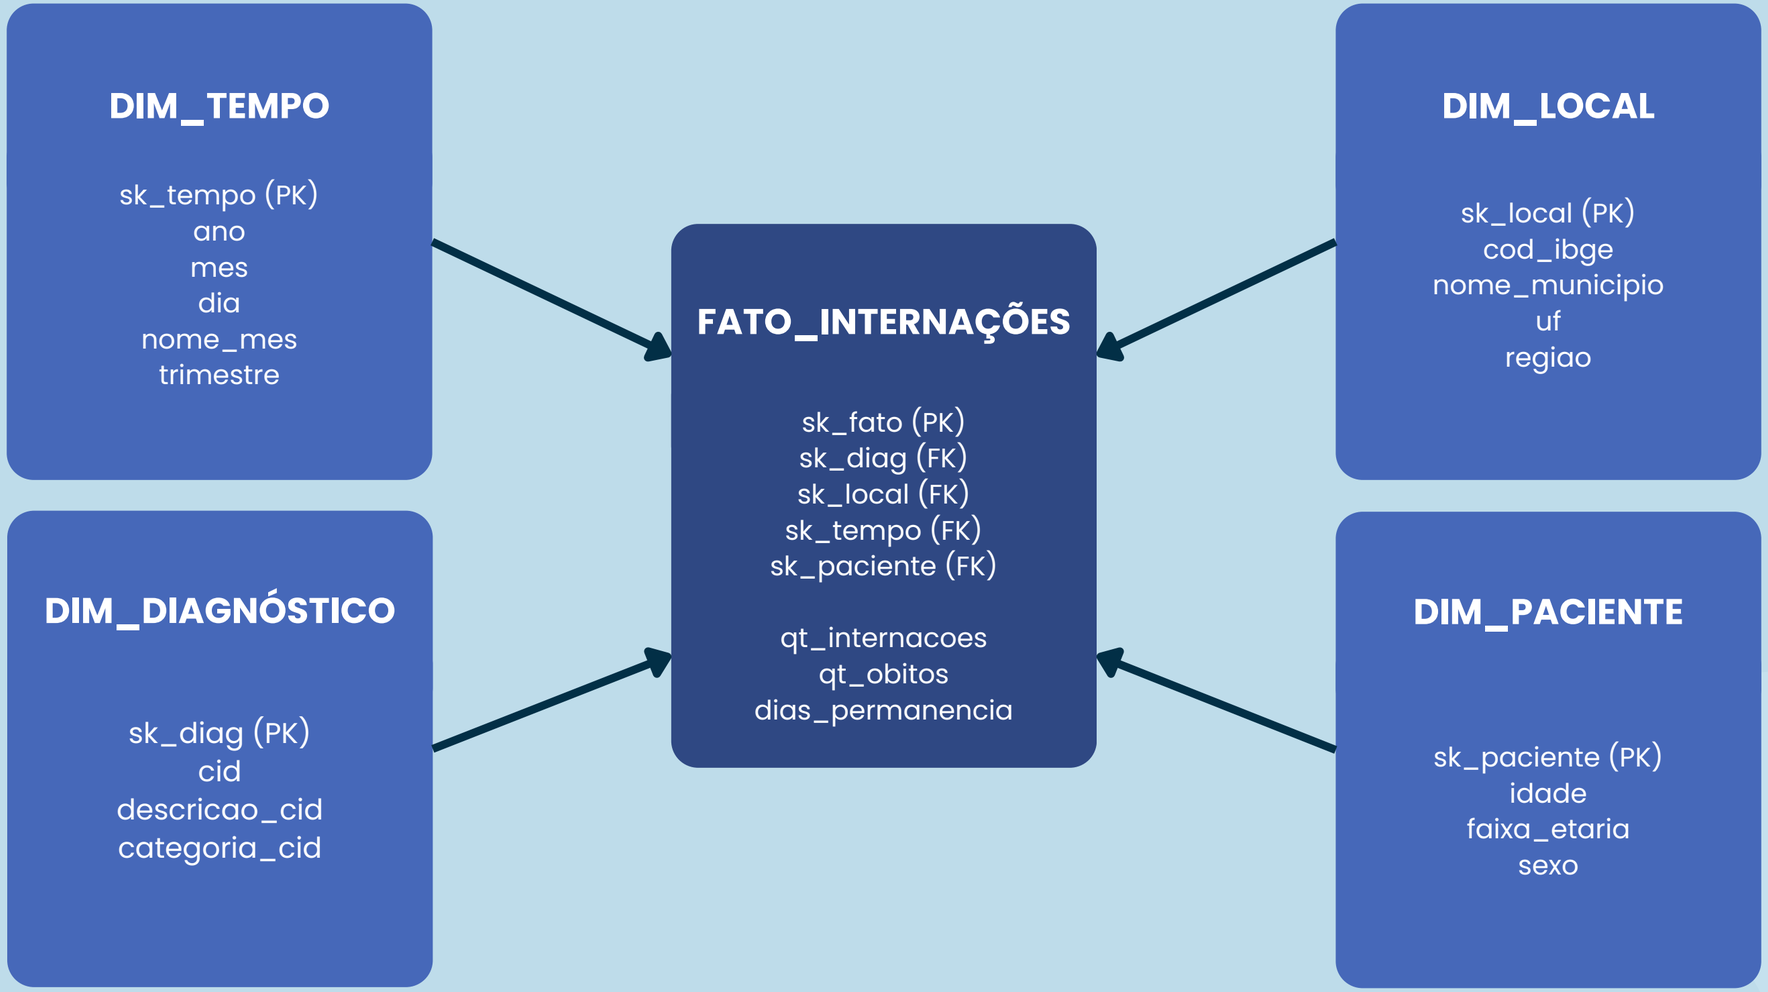

PIPELINE ETL/ELT FUNCIONAL

Extração dos dados

Origem	Download	Armazenamento RAW
FTP DATASUS Servidor do governo federal	**Arquivo .dbc** Convertido automaticamente	**.parquet** Mais leve e eficiente que um csv

PIPELINE ETL/ELT FUNCIONAL

Extração dos dados

Nessa função o primeiro passo é definir os valores que serão utilizados na extração dos dados, como **estado**, **ano** e **mês**.

A chamada **SIH.download** é o ponto central dessa etapa, pois é ela que realiza o acesso direto aos dados do **DATASUS** e retorna as informações de internações hospitalares.

```python
def extrair_dados_datasus(
    estados: list = None,
    anos: list = None,
    meses: list = None,
    caminho_saida: str = "data/raw/sih_to_2023_01.parquet",
) -> pd.DataFrame:
    estados = estados or ["TO"]
    anos = anos or [2023]
    meses = meses or [1]
```

```python
dados = SIH.download(states=estados, years=anos, months=meses, groups=["RD"])
```

PIPELINE ETL/ELT FUNCIONAL

Extração dos dados

Na função **exportar_para_sql**, o objetivo é pegar o DataFrame criado e colocá-lo dentro de um banco de dados.

Após salvar os dados no banco, o código gera um dump em SQL abrindo a conexão com o **SQLite** e recriando o banco em um arquivo .sql.

```python
def exportar_para_sql(
    df: pd.DataFrame,
    table_name: str = "sih_internamentos",
    db_path: str = "data/processed/sih_datasus.db",
) -> None:
    os.makedirs(os.path.dirname(db_path), exist_ok=True)

    engine = create_engine(f"sqlite:///{db_path}")
    df.to_sql(table_name, engine, if_exists="replace", index=False)
    logger.info("Tabela '%s' exportada para o banco: %s", table_name, db_path)

    dump_path = db_path.replace(".db", ".sql")
    with sqlite3.connect(db_path) as conn:
        with open(dump_path, "w", encoding="utf-8") as f:
            for line in conn.iterdump():
                f.write(f"{line}\n")
```

PIPELINE ETL/ELT FUNCIONAL

Limpeza e organização dos dados

O código começa definindo alguns **mapas de domínio** que serão usados ao longo da transformação dos dados. Esses mapas servem para traduzir códigos em informações mais compreensíveis.

```python
NOMES_MES = [
    "Janeiro", "Fevereiro", "Março", "Abril",
    "Maio", "Junho", "Julho", "Agosto", "Setembro",
    "Outubro", "Novembro", "Dezembro",
]
```

```python
SEXO_MAP = {"1": "Masculino", "3": "Feminino", "0": "Ignorado"}
```

PIPELINE ETL/ELT FUNCIONAL

Limpeza e organização dos dados

A função **categoria_cid** trata o CID analisa o código do diagnóstico e retorna a categoria correspondente.

```python
def categoria_cid(cid: str) -> str:
    if not isinstance(cid, str) or len(cid) < 3:
        return "Desconhecido"
    letra = cid[0].upper()
    try:
        int(cid[1:3])
    except ValueError:
        return "Desconhecido"
    return CATEGORIAS_CID.get(letra, "Desconhecido")
```

A função de **faixa_etaria** transforma uma idade numérica em uma classificação mais descritiva.

```python
def faixa_etaria(idade) -> str:
    try:
        idade = int(idade)
    except (ValueError, TypeError):
        return "Desconhecida"
    if idade < 2:   return "Lactância"
    if idade <= 4:  return "Primeira infância"
    if idade <= 10: return "Segunda infância"
    if idade <= 13: return "Pré-adolescência"
    if idade <= 18: return "Adolescência"
    if idade <= 26: return "Pós-adolescência"
    if idade <= 40: return "Adultidade"
    if idade <= 65: return "Meia-idade"
    if idade <= 80: return "Terceira idade"
    return "Quarta idade"
```

PIPELINE ETL/ELT FUNCIONAL

Estruturação das dimensões

DIM_TEMPO

O código extrai **ano**, **mês** e **dia** a partir da data de internação e adiciona **nome do mês** e **trimestre**.

DIM_LOCAL

o código utiliza o município de residência, associa ao nome da **cidade** e identifica a **UF** e a **região**.

DIM_PACIENTE

Os dados de **idade** e **sexo** são padronizados e transformados em categorias como **faixa etária**.

DIM_DIAGNOSTICO

O código **CID** é validado e associado a uma categoria de doença, permitindo agrupar os diagnósticos.

PIPELINE ETL/ELT FUNCIONAL

Estruturação da Fato

```python
def build_fato(
    df: pd.DataFrame,
    dim_tempo: pd.DataFrame,
    dim_local: pd.DataFrame,
    dim_paciente: pd.DataFrame,
    dim_diag: pd.DataFrame,
) -> pd.DataFrame:

    trabalho = df.copy()

    dt_inter = trabalho["DT_INTER"].astype("string").str.strip()
    dt_valida = dt_inter.str.fullmatch(r"\d{8}", na=False)
    trabalho[["_ano", "_mes", "_dia"]] = None
```

```python
    dt_inter = trabalho["DT_INTER"].astype("string").str.strip()
    dt_valida = dt_inter.str.fullmatch(r"\d{8}", na=False)
    trabalho[["_ano", "_mes", "_dia"]] = None

    trabalho.loc[dt_valida, "_ano"] = pd.to_numeric(dt_inter[dt_valida].str[0:4], errors="coerce")
    trabalho.loc[dt_valida, "_mes"] = pd.to_numeric(dt_inter[dt_valida].str[4:6], errors="coerce")
    trabalho.loc[dt_valida, "_dia"] = pd.to_numeric(dt_inter[dt_valida].str[6:8], errors="coerce")

    fato_tempo = dim_tempo.rename(columns={"ano": "_ano", "mes": "_mes", "dia": "_dia"})[
        ["sk_tempo", "_ano", "_mes", "_dia"]
    ]
```

A tabela fato integra os dados brutos com as dimensões ao relacionar cada registro de internação com **tempo**, **local**, **paciente** e **diagnóstico**.

Depois disso, são criadas as métricas principais, como quantidade de **internações**, número de **óbitos**, etc..

O resultado final é uma tabela onde cada linha representa **uma internação**.

CARGA DE DADOS: DATAMART FISICO

- Uso do SQLite como motor de banco de dados leve e eficiente.
- Automação via SQLAlchemy no script transformar.py.
- Criação das tabelas do modelo Star Schema (1 Fato, 4 Dimensões).
- Banco pronto para consumo pelas ferramentas de BI (sih_datasus.db).

REPRODUTIBILIDADE E BACKUP: O DUMP SQL

- Geração do arquivo sih_datasus.sql.
- Contém todos os comandos CREATE TABLE e INSERT INTO.
- **Objetivo:** Permite recriar todo o Data Mart em qualquer outro SGBD (PostgreSQL, MySQL) sem precisar rodar os scripts Python novamente.
- Facilidade de versionamento e compartilhamento do projeto.

PERGUNTAS DE NEGÓCIO

Qual é o total de internações e óbitos por município?

Qual é a faixa etária com o maior tempo médio de permanência hospitalar?

Qual é a taxa de letalidade hospitalar agrupada por sexo

Quais são as 5 principais categorias de diagnóstico (CID) que resultam em internação?

Qual é a evolução mensal da quantidade de internações ao longo do ano analisado?

QUAL É O TOTAL DE INTERNAÇÕES E ÓBITOS POR MUNICÍPIO?

Total de 7795
Sendo **948 internações** e **37 óbitos** em **Araguaína**
1336 internações e **31 óbitos** em **Talismã**
365 internações e **18 óbitos** em **Guaraí**

QUAL É A FAIXA ETÁRIA COM O MAIOR TEMPO MÉDIO DE PERMANÊNCIA HOSPITALAR?

Lactância (até 2 anos de idade)
8,65% de tempo médio

QUAIS SÃO AS 5 PRINCIPAIS CATEGORIAS DE DIAGNÓSTICO (CID) QUE RESULTAM EM INTERNAÇÃO?

Gravidez
Lesões e causas externas
Doenças do aparelho **digestivo**
Doenças do aparelho **Circulatório**
Doenças do aparelho **Respiratório**

QUAL É A TAXA DE LETALIDADE HOSPITALAR AGRUPADA POR SEXO?

Masculino **4,27%**
Feminino **2,49%**

QUAL É A EVOLUÇÃO MENSAL DA QUANTIDADE DE INTERNAÇÕES AO LONGO DO ANO ANALISADO?

Estabilidade no **início** do período
Aumento expressivo em **agosto**
Queda gradual entre **setembro** e **novembro**
Leve **aumento** em **dezembro**

Dashboard

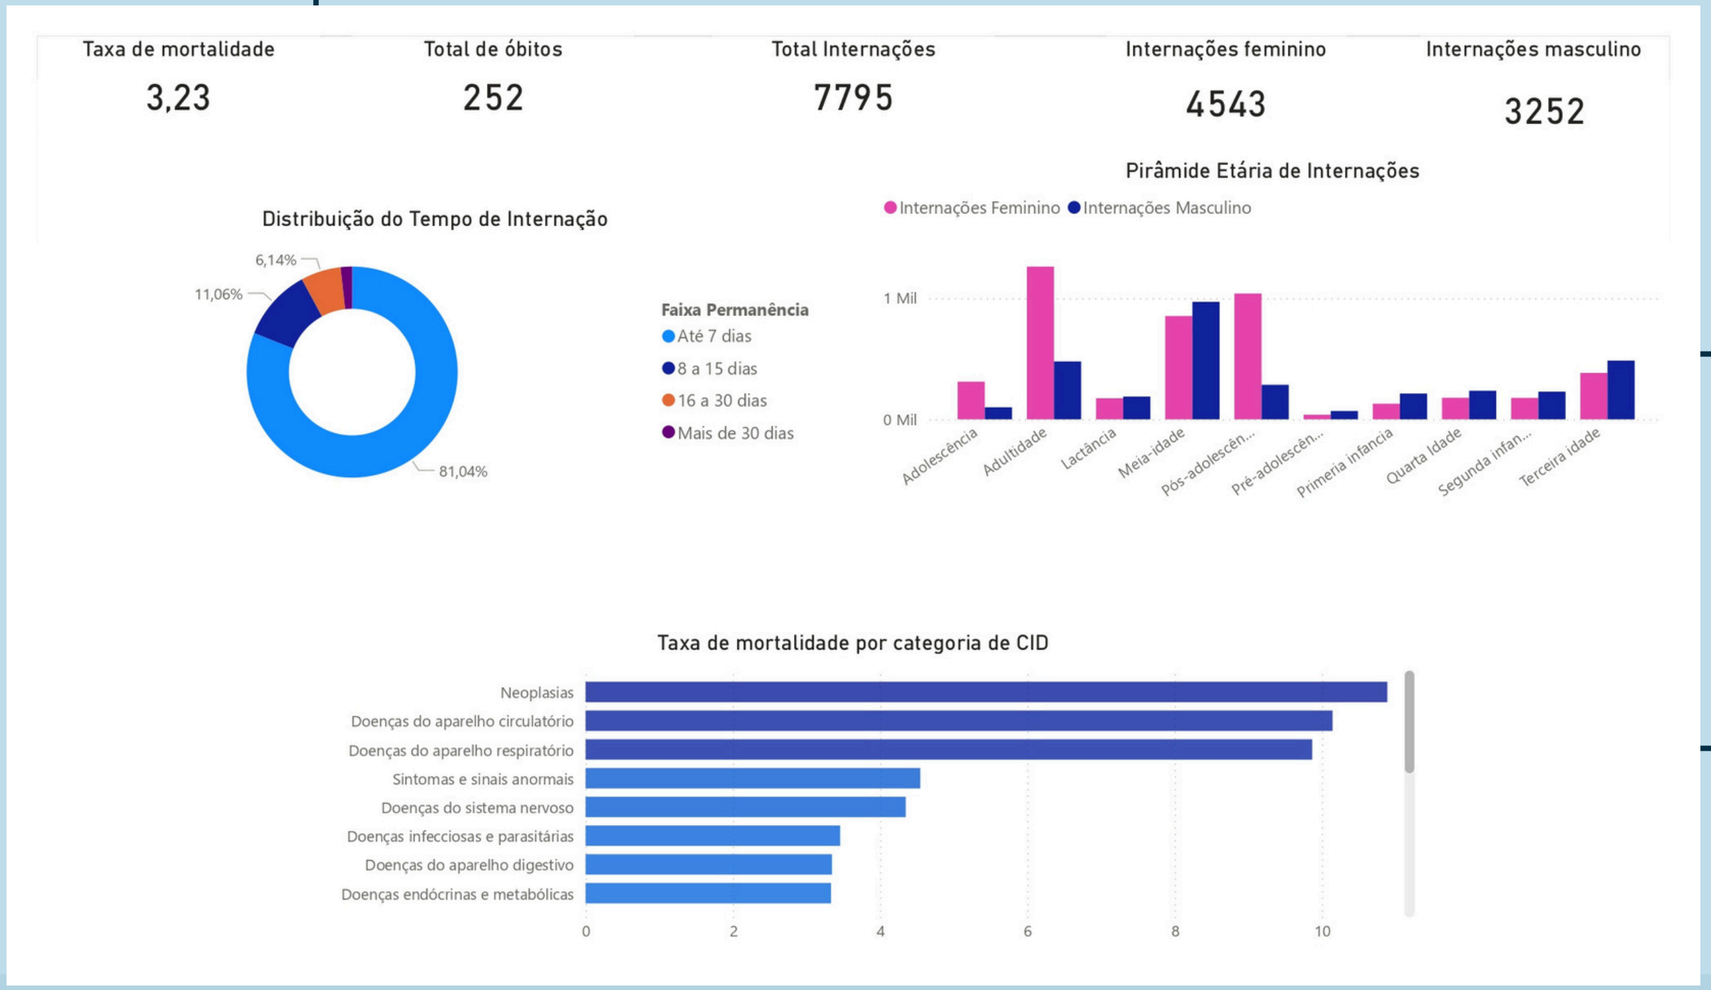

Distribuição do Tempo de Internação

Pirâmide Etária de Internações

Taxa de mortalidade por categoria de CID

Conclusão!

Com base nas **análises realizadas,** o dashboard permite **identificar padrões importantes** relacionados à **demanda hospitalar**, perfil dos pacientes e **comportamento das internações** ao longo do tempo.

Essas informações podem apoiar gestores de saúde na **tomada de decisão**, planejamento de **recursos hospitalares** e **identificação de áreas que demandam maior atenção no sistema de saúde.**

OBRIGADO!